

BLOQUE I: 1. SISTEMAS BÁSICOS EN EL CONOCIMIENTO

- Incertidumbre: Es probable que hoy llueva } Depende de si el sistema es incierto o
- Imprecisión: Tuviste un brote alto } impreciso trabajaremos de forma distinta

- Sistema basado en el conocimiento: APP informática capaz de solucionar un conjunto de problemas que exigen un gran conocimiento sobre un determinado tema.

Ej: en una APP de diagnóstico sanitario se recogen datos del paciente, síntomas...

El sistema a partir de esto puede dar como resultado → emitir diagnóstico

↓ ↓ ↓
aprender de los justificar la dictar nueva
nuevos casos respuesta información

todos esto hace que el
sistema necesite
mecanismos de
razonamiento

- Técnicas de razonamiento
- * Lógica (A.C - actualidad): proposicional, de predicados, descriptiva
 - * Lógica difusa (1965 - actualidad)
 - Modelo probabilístico clásico (70-80)
 - Factores de certeza (75-80)
 - * Redes bayesianas (88 - actualidad)

Razonamiento aproximado: El modelo ideal del razonamiento es el exacto pero en el mundo real se suele razonar con información incierta (redes bayesianas) e imprecisa (lógica difusa) debido a información incompleta, errónea, imprecisa...

REDES BAYESIANAS: características principales

- La incertidumbre se representa basándose en teoría de la probabilidad

- Información estructurada en variables y relacionadas con influencia causal

- Parámetros: probabilidades condicionales de cada variable dadas sus padres

- Inferencias abductivas y predictivas

↑ ↓
abducción predicción

LOGICA DIFUSA: características principales

- Motivación inicial: estudio de la vaguedad

- Solución: definir conjuntos con grados de pertenencia

Objetivo: representar la vaguedad e imprecisión inherentes en el lenguaje natural

Elementos: conjuntos difusos, variables difusas, relaciones difusas, reglas difusas que se combinan entre sí en el proceso de inferencias

incluye pasos que pasan la información nítida a difusa y viceversa.

**FUNCIONALIDADES
QUE DEBE TENER
UN SBC**

- Aceptar las consultas que el usuario realice
- Aceptar los datos proporcionados por el usuario y rechazar otros, que el sistema estime
- Procesar esta información en función de una respuesta a la consulta planteada
- Emitir la respuesta finalizada, que normalmente debe ser análoga a las respuestas de un experto
- Justificar la respuesta emitida
- Aprendizaje (o que sea posible)

{ En la base de conocimiento: reglas o Reglas bayesianas

En motor de inferencia: acepta los datos

En memoria de trabajo: conclusiones intermedias y finales; esto cambia en cada acción

SBC basados en reglas: base de conocimientos

- Contiene: conocimiento experto expresado en reglas
- Naturaleza: estática si no interviene el módulo de adquisición de conocimientos y, al revés, incluye elementos de aprendizaje.
- Representación del conocimiento: de forma computable bien sea en reglas, relaciones de diferencia entre...
- Tiene flexibilidad con los reglas → Reglas de diagnóstico: Si los ent grape
→ Reglas causal: Si grape ent los.

**Representación
basada en
reglas**

- Hechos: afirmaciones irreducibles
 - Simples: "cantidad de ropa es mucha"
 - Compuestas: "cantidad de ropa es mucha y grado de suciedad alto" utiliza conectivos Y, NO, O para agrupar hechos simples.
- Reglas: estructuras de razonamiento fundamentales Ej: si (izq) entonces (der)
 - Terminología: (izq) antecedente, premisa o condición.
 - (der) consecuente, conclusión, acción.

En una red de inferencias hay: hipótesis inicial, intermedia y finales

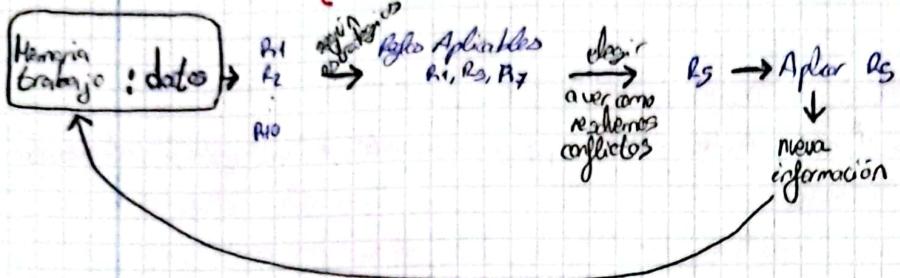
SBC basadas en reglas: memoria de trabajo

- Contiene: conclusiones/hipótesis que se generan en el proceso de razonamiento a partir de los datos del caso que se esté considerando
- Naturaleza: dinámica pues se van creando hipótesis/conclusiones

- Utilizar datos almacenados en la memoria de trabajo
 - conocimiento almacenado en la base de conocimiento
- } para obtener nuevos
conclusiones/hipótesis que se ordenan
la HT.

El motor de inferencia puede solicitar también nuevos datos al usuario, cuando intenta probar alguna hipótesis.

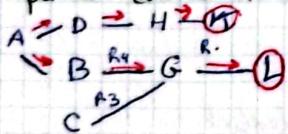
Razonamiento para sacar conclusiones en reglas	Regla Modus Ponens	Regla Modus Tollens
	Regla: Si A es cierto, entonces B es cierto Hecho: A es cierto Se concluye que B es cierto	Regla: Si A es cierto, entonces B es cierto Hecho: B es falso Se concluye que A es falso



Si $B \wedge C$ la conclusión es K
 Si $B \vee C$ las conclusiones son K y L

} porque solo tenemos
de dato inicial A.

Ej: (Supuesto 1'): Motor hacia adelante, orden textual para resolución de conflictos, criterio parada cuando no hay más reglas aplicables, $B \rightarrow G \wedge C \rightarrow G$



Para demostrar: partimos de la hipótesis que queremos demostrar y del dato inicial. Partimos del que queremos demostrar y miramos su antecedente, si está en la memoria de trabajo sacamos sino nos movemos al antecedente y miramos si está en la memoria de trabajo...

Estrategias: lo normal es que insistiera, mire porcialmente hacia adelante y porcialmente hacia atrás

Hay que determinar

Estrategias: para decidir el conjunto de reglas aplicables
Cómo resolver conflictos: cuando haya más de un regla aplicable
-Configuración final: qué se considera

Estrategias de los motores de inferencia

Encañamiento de reglas hacia adelante: partimos de un objetivo a demostrar y vamos hacia adelante intentando probarlo, basando los hechos que nos permiten concluir dicho objetivo
En la práctica se plantea o se pide deducir el objetivo
El sistema se ha implementado para o pidiendo evidencias

CRITERIOS DE RESOLUCIÓN DE CONFLICTOS

Estaticos: orden textual de reglas, utilidad reglas, utilidad leches, especificidad, generalidad.

Dinámicos: mínima espera, máxima espera.

Dinámicos manipulables: los parámetros que determinan la prioridad se modifican en el tiempo mediante meta-reglas.

CRITERIOS DE PARADA

- aquella que contiene el menor de hipótesis final
- aquella que contiene d. hipótesis final con un menor grado de generalidad
- aquella en la que no es posible aplicar más reglas

Def: configuraciones finales de la memoria de trabajo

Ej: hipótesis intermedia es el motor recibe gasolina pq es consecuente d una regla, cibertiente de otra.

(Supuesto 2)

MT = { hay gasolina, motor no enciende, luces encienden }

Reglas aplicables = { R4, R3 }

Res. conflictos: ver si llegan a confl. final.

MT = { no hay gasolina, hay gasolina, motor no enciende, luces encienden }

Reglas aplicables = { R3, R1 }

MT = { arranque, recibe gasolina, hay gasolina, motor no enciende, luces encienden }

Reglas aplicables = { R1 }

MT = { bujías, arranque, recibe gasolina, hay gasolina, motor no enciende, luces encienden }

Ejercicio 1: No es posible aplicar más reglas y resolución orden textual

(Supuesto 1): Motor eng hacia delante

MT = { rueda, piere huevos, cuello largo }

Regla aplicable = { R2 }

Res. conflictos: R2

Cgf. final: NO

MT = { rueda, piere huevos, cuello largo, ave }

Regla aplicable = { R13 }

Res. conflictos: R13

Cgf. final: si → conclusión: Robbie es un albinos

(Supuesto 2): Motor eng hacia atrás

MT = { Llave pdo, dientes protagudos, gris, espastones, rayos negros, olor bronco, en lata }

Hay qe demostrar: monstruo y carrivela R4

Hay qe demostrar: carrivela ←

Ejercicio 2:

H1: Juan en España, Alberto en Francia, Carmen en Egipto }

R1: Si Tomás está en Francia, el Juan no está en Egipto

R2: Si Tomás no está en Francia, el Juan está en Egipto

R3: Si Tomás está en Egipto, el Alberto no está en Francia

R4: Si Tomás no está en Egipto, el Alberto está en Francia

R5: Si Tomás está en Egipto, el Carmen no está en Egipto

R6: Si Tomás no está en Egipto, el Carmen está en Egipto

R7: Si Tomás está en Japón, el Carmen no está en Francia

R8: Si Tomás no está en Japón, el Carmen está en Francia

Como 2 personas no pueden estar en 2 países suponemos que una de las dos afirmaciones es falsa por lo que Tomás está en Egipto o en Japón, Juan en España, Alberto en Francia.

Con esto llegamos a que Carmen está en Egipto o en Francia, sin embargo sabemos que Carmen no puede estar en Francia puesto que si así Alberto estaría en Francia. Esto nos lleva a que Carmen está en Egipto. El único pas que queda es que Tomás está en Japón, por lo que vamos a intentar darlo.

BLOQUE I: 2. REDES BAYESIANAS

REPASO CONCEPTOS PROBABILIDAD

$$\text{Probabilidad condicionada: } P(X|Y) = \frac{P(X,Y)}{P(Y)}$$

Dos variables son independientes si: $P(X,Y) = P(X) \cdot P(Y)$

Característica X e Y son independientes si: $P(X,Y) = P(X) \cdot P(Y)$ = la prob. conjunta se presta factorizar
dato. marginales

E distribución de prob. conjunta para X e Y

$$x \begin{cases} s_1 \\ n_0 \end{cases} \quad y \begin{cases} s_1 \\ n_0 \end{cases}$$

$P(X=s_1, Y=s_1) = 0,2$
$P(X=s_1, Y=n_0) = 0,2$
$P(X=n_0, Y=s_1) = 0,2$
$P(X=n_0, Y=n_0) = 0,4$

Necesitamos $2^2 = 4$ datos

$$P(X=s_1) = P(X=s_1, Y=s_1) + P(X=s_1, Y=n_0) = 0,2 + 0,2 = 0,4$$

marginalizar:

$$P(X=s) = \sum_i P(X=s, Y=i)$$

$$\text{Th. Bayes (Th. interacción): } P(Y|X) = \frac{P(X|Y) \cdot P(Y)}{P(X)}$$

Ley de probabilidad total: Si y_1, \dots, y_n un conj. de valores exhaustivos y excluyentes

$$P(X) = \sum_{i=1}^n P(X|Y_i) \cdot P(Y_i)$$

Generalización

$$P(Y_1, Y_2) = \sum_X P(Y_1|X, Y_2) \cdot P(X|Y_2)$$

Independencia condicional: De X e Y respecto a Z si: $P(X|Y, Z) = P(X|Z)$

Prueba de independencia condicional: $\forall i, j, k, l \in \{1, \dots, n\}, P(X=i, Y=j | Z=k, Z=l) = P(X=i | Z=k) \cdot P(Y=j | Z=l)$ o $X \perp\!\!\!\perp Y | Z$

Ej: Método probabilístico clásico

Neceitamos $2^5 - 1$ datos de probabilidad

$$P(E=S, O=S, H=S, J=S, V=S) = \frac{\text{acor. favorables}}{\text{acor. totales}} = \frac{1}{20}$$

A partir de la frecuencia observada podemos calcular sus probabilidades

PRESENTACIÓN INTUITIVA

- En una red bayesiana, cada nodo corresponde a una variable, que a su vez representa una entidad del mundo real.
- Los arcos que unen los nodos representan relaciones de influencia causal

X = variable/nodo

x = valor

Ej 1:

$$x_1 \rightarrow x_2 \rightarrow x_3 \rightarrow \dots \rightarrow x_{10} \quad 1 \quad 2 \quad 2 \quad 2 = 18 + 1 = 19 \leq \frac{2^{10} - 1}{\text{nos quedamos con } 19 \text{ casos}}$$

- **Predisposición**: cuento porcentaje de la población lo están padeciendo ahora mismo

- **Sensibilidad**: verdaderos positivos } En medicina se hacen las pruebas con mayor grado

- **Especificidad**: verdaderos negativos } de sensibilidad y especificidad.

$$P(+y_1) = P(+y_1/x_1) \cdot P(x_1) + P(+y_1/\neg x_1) \cdot P(\neg x_1) = \text{a priori}$$

Infrecias a partir de los datos = sabiendo y cuál es la prob de x

↳ Probabilidades a posteriori dada una evidencia observada.

$P(x)$ = probabilidad a priori de x Ej: P(sacar 4) = 1/6

$P^*(x) = P(x/y)$ = probabilidad a posteriori. Ej: P(sacar 4 / ha salido pr) = 1/3

$$\text{Th. Bayes} = P^*(x) = P(x/y) = \frac{P(y/x) \cdot P(x)}{P(y)} = \alpha \cdot P(x) \cdot \lambda(x)$$

$$\alpha = [P(y)]^{-1}$$

$$\lambda(x) = P(y/x)$$

$$P^*(+x) = \alpha \cdot P(+x) \cdot P(+y/x)$$

$$P^*(\neg x) = \alpha \cdot P(\neg x) \cdot P(\neg y/x)$$

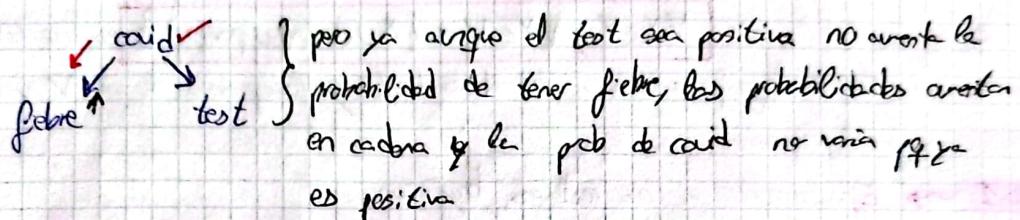
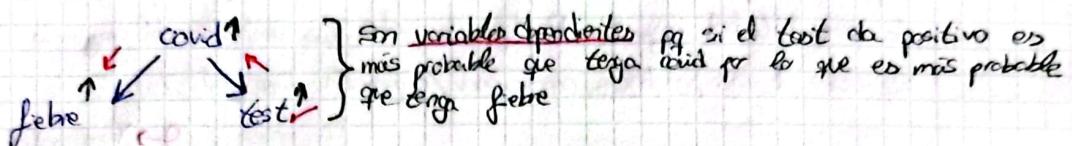
$$\text{Ej 2: } P(\text{covid}) = 0,099$$

$$P^*(\text{covid}) = P(\text{covid}/\text{antígeno}) = 0,66$$

$P(\text{covid}/\text{febre}) = 0,44 \rightarrow$ es más probable tener covid si solo sabemos que tiene fiebre que tener covid en el test

$$P^*(x) = P(x/y_1, y_2) = \frac{P(x) \cdot P(y_1, y_2/x)}{P(y_1, y_2)}$$

$$P(y_1, y_2/x) \stackrel{\text{si } y_1 \text{ es } \text{indep de } y_2 \text{ dada } x}{=} P(y_1/x) \cdot P(y_2/x) \quad ; \quad d(x) = dy_1(x) \cdot dy_2(x) \Rightarrow P(x) = dP(x)$$



$$\text{Ej: } P(x/y_2, \neg y_1)$$

$$P^*(+x) = P(x/y_2, \neg y_1) = \frac{P(\neg y_1, y_2/x) \cdot P(x)}{P(\neg y_1, y_2)} = \alpha \cdot P(x) \cdot P(\neg y_1/x) \cdot P(y_2/x) = \alpha \cdot 0,099 \cdot 0,1 \cdot 0,1 = 0,00594$$

$$P^*(\neg x) = \alpha \cdot P(\neg x) \cdot P(y_2/\neg x) \cdot P(\neg y_1/\neg x) = \alpha \cdot 0,901 \cdot 0,1 \cdot 0,95 = 0,085545$$

$$\alpha = \frac{1}{0,00594 + 0,085545} = \frac{1}{0,09135} = 1,092478$$

$$0,00594 \cdot 1,092478 = 0,00649$$

Probabilidad de los 2 hijos:

$$P(y_1/y_2) = P(+y_1) = \alpha \cdot [P(x) \cdot P(y_1/x) \cdot P(\neg x) \cdot P(y_1/\neg x)] = 0,099 \cdot 0,9 \cdot 0,001 \cdot 0,95 = 0,008143$$

$$P(\neg y_1/y_2) = P^*(\neg y_1) = \alpha \cdot [P(x) \cdot P(\neg y_1/x) \cdot P(\neg x) \cdot P(y_1/\neg x)] = 0,099 \cdot 0,1 \cdot 0,001 \cdot 0,95 = 0,008143$$

$$\text{Ej: } P(y_2/y_1)$$

$$P(+y_2) = \alpha \cdot [P(x) \cdot P(y_2/x) \cdot P(\neg x) \cdot P(y_2/\neg x)] = \alpha \cdot 0,099 \cdot 0,6 \cdot 0,901 \cdot 0,1 = 0,053$$

$$P^*(y_2) = \alpha \cdot [P(x) \cdot P(\neg y_2/x) \cdot P(\neg x) \cdot P(y_2/\neg x)] = \alpha \cdot 0,099 \cdot 0,4 \cdot 0,901 \cdot 0,9 = 0,0321$$

$$\alpha = \frac{1}{0,008143 + 0,0321} = \frac{1}{0,0375} = 26,667 \rightarrow 26,667 \cdot 0,00649 = 0,143$$

REDES BAYESIANAS

Variable aleatoria que toma un eje exhaustivo y excluyente de valores.

- Red Bayesiana \Leftrightarrow un conjunto de variables proposicionales V ;
- \Leftrightarrow un conjunto de relaciones binarias definidas sobre V, E ;
 - \Leftrightarrow una distribución de probabilidad conjunta P sobre las variables de V .

- tales que (V, E) forman un grafo acíclico, conexo y dirigido G
- $\Leftrightarrow (G, P)$ cumplen la hipótesis de independencia condicional/separación directa

- Extensión: cubre todo el rango de valores posibles.

- Galería: es un vértice en el anterior del otro

Pueden ser variables proposicionales aquellas que aparien veces que no poco rotuladas su mundo. (3)

Hipótesis Independencia Condicional: en grafo acíclico, conexo y dirigido $G = (V, E)$ y una distribución de probabilidad conjunta P definida sobre las variables del grafo se dice que cumplen las hipótesis de independencia condicional/separación directa si:

$\rightarrow X$ es ind. de Y dado $p(x)$

$$\forall X \in V, \forall Y \in V - \{X\} \text{ dada } p(x) \}$$

Si en el grafo quitamos los descendientes y los padres de $X \in V$ y quedan ellos en pie son independientes.

Ej: Comprobar si una red es bayesiana.

1. Variables proposicionales? Sí pq cada variable es sí o no

2. Grafo conexo, acíclico y dirigido? Sí

3. Condiciones de independencia?

\rightarrow Para A: $A : Y \in V - \{A, B, C\} = \emptyset$ No existe cond. de independencia

\rightarrow Para B: $B : Y \in V - \{B, A\} = C \Rightarrow B : C$ dado A los padres de B

No es necesario comprobar C pq la red es simétrica

$B : C$ dado $A = P(B/A, C) = P(B/A) \rightarrow$ tengo qe demostrar qe indep. de C el resultado no varía.)

$$\rightarrow P(b_1/a_1, c_1) = P(b_1/a_1)$$

$$\left. \begin{array}{l} P(b_1/a_1, c_1) = P(a_1, b_1, c_1) / P(a_1, c_1) = 0,05 / 0,2 = 1/4 \\ P(b_1/a_1) = P(b_1, a_1) / P(a_1) = 0,15 / 0,3 = 1/2 \end{array} \right\} \text{Como no es igual para todos los caso continuo qe no es bayesiana}$$

Ej: V.prop = 3C ; G.Cpx, acíclico, dirigido = Sí ; cond. independencia:

\rightarrow Para A: $A : Y \in V - \{A, B, C\} = \emptyset$

\rightarrow Para B: $B : Y \in V - \{B, A\} = C \Rightarrow B : C$ dado $A = P(B/A, C) = P(B/A) ?$

$$P(b_1/a_1, c_1) = 0,084 / (0,084 + 0,126) = 0,4 \Rightarrow P(b_1/a_1) = (0,084 + 0,036) / (0,084 + 0,126 + 0,036 + 0,027) = 0,4$$

$$P(b_1/a_2, c_1) = 0,084 / 0,14 = 0,6 \Rightarrow P(b_1/a_2) = 0,6$$

$$P(b_1/a_1, c_2) = 0,036 / 0,09 = 0,4 \Rightarrow P(b_1/a_1) = 0,4 \quad \text{Continuo qe es bayesiana}$$

$$P(b_2/a_1, c_1) = 0,126 \Rightarrow P(b_2/a_1) = 0,6$$

$$P(b_2/a_2, c_1) = 0,126 \Rightarrow P(b_2/a_2) = 0,4$$

$$P(b_2/a_1, c_2) = 0,126 \Rightarrow P(b_2/a_1) = 0,6$$

Tipo 2 \rightarrow Ej: ¿Qué independencia implica la red?

$$\forall x \in V, x: y \in \{v - f(x) \cup d(x) \cup pa(x)\} \text{ dado } pa(x)$$

$$x = S \rightarrow x: y \in \{S, T\}$$

$$x = S \rightarrow x: y \in \{S, T\} \text{ padres } x$$

$$x = S \rightarrow x: y \in \{S, T, D\} \text{ — aquí no tiene padres pero no es puro}$$

$$x = D \rightarrow x: y \in \{S, T, F, S\} \text{ dado } D$$

$$x = F \rightarrow x: y \in \{S, T, D\} \text{ dado } F, S, D$$

Ej:

$$x = A \rightarrow x: y \in \{S, B\}$$

$$x = S \rightarrow x: y \in \{A, T\}$$

$$x = T \rightarrow x: y \in \{S, B\} \text{ dado } A$$

$$x = L \rightarrow x: y \in \{B, A, T\} \text{ dado } S$$

$$x = B \rightarrow x: y \in \{A, T, L, C, X\} \text{ dado } S$$

$$x = E \rightarrow x: y \in \{A, S, B\} \text{ dado } T, L$$

$$x = X \rightarrow x: y \in \{A, B, T, L, B, D\} \text{ dado } E$$

$$x = D \rightarrow x: y \in \{A, S, T, L, X\} \text{ dado } E, B$$

Ej:

Ganadora: $B: C$ dado A

Cabecita con cabecita: $B: C / C: B$

Cabecita con cola: $A: C$ dado $B / C: A$ dado B — anexo al aplicarlos a A nos da la independencia como $A: C$ si se sabe que el revés tiene que ser igual pq es simétrico.

TH. FUNDAMENTAL: FACTORIZACIÓN DE LA PROBABILIDAD

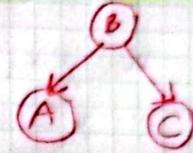
Dada una red bayesiana, su distribución de probabilidad puede expresarse como: $P(x_1, x_2, \dots, x_n) = \prod P(x_i | pa(x_i))$

Nos permite describir una red bayesiana a partir de las probabilidades condicionales de cada nodo dados sus padres en lugar de a partir de la probabilidad conjunta que

→ requiere un nº de parámetros exponencial en el nº de nodos

→ plantea el problema de verificar la independencia condicional

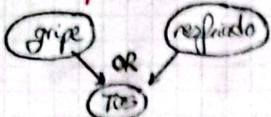
No hace falta $P(x_1, x_2, \dots, x_n) \rightarrow \prod P(x_i | pa(x_i)) = P(x_1) \cdot P(x_2 | x_1) \cdot P(x_3 | x_2)$



$A: C$ dado B = Una vez que se conoce el valor de B , el valor de A no proporciona información adicional sobre el valor de C , viceversa

MODELADO CON PGDS BAYESIANAS

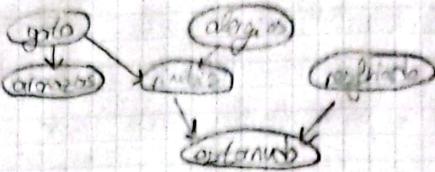
Relación tipo OR



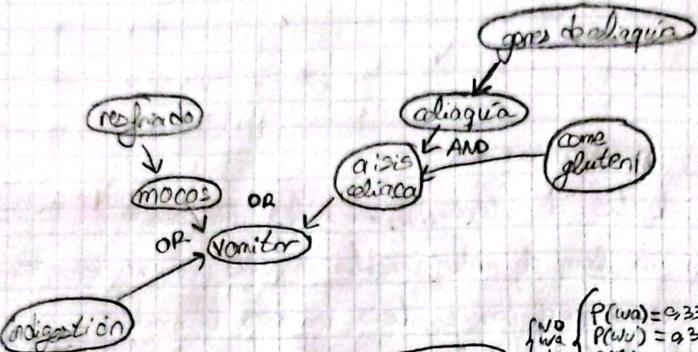
$$\begin{cases} P(\text{tos}/\text{gripe, resfriado}) = 0,75 \\ P(\text{tos}/\text{gripe, resfriado}) = 0,05 \\ P(\text{tos}/\text{gripe, resfriado}) = 0,25 \\ P(\text{tos}/\text{gripe, resfriado}) = 0,2 \end{cases}$$

Si se nos hace difícil poner en probabilidad dadas, agrégante la red este mal.

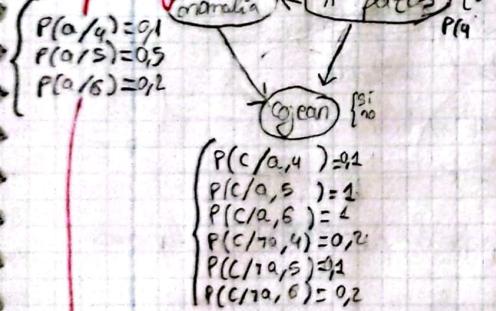
Ej:



Ej:



Ej:



$$\begin{cases} \text{No wa} \\ \text{Wa} \end{cases} \quad \begin{cases} P(wa) = 0,33 \\ P(wu) = 0,33 \\ P(wo) = 0,33 \end{cases}$$

$$\begin{cases} \text{Edad} \\ \text{Sexo} \end{cases} \quad \begin{cases} P(s/wa) = 1 \\ P(s/wu) = 0,5 \\ P(s/wo) = 0,2 \\ P(s/wa) = 0,8 \\ P(s/wu) = 0,5 \\ P(s/wo) = 0,2 \end{cases}$$

relaciones de clasificación

MODELADO CON REDES BAYESIANAS

- Modelos: representación selectiva de la realidad

- Modelado: proceso de construir modelos y en el enfoque de redes bayesianas...

constar

Modelo Causalitativo

se definen
se definen

Nodos/VARIABLES

obten tienen un espacio exhaustivo y excluyente
de valores

Relaciones entre nodos: dan respuesta influencia causal

Modelo Quantitativo

Por el th. fundamental, los parámetros necesarios son las distribuciones de probabilidad condicionada de cada nodo dados sus padres (incluyendo la probabilidad a priori de los nodos sin padre)

TIPO VARIABLE

DESCRIPCION

Objetivo → modelan objetos de interés. No observables directamente

Observación → modelan la forma de medir variables objetivo. Pueden ser observados directamente

Factor → modelan fenómenos que afectan a otras variables del modelo

Promotor → la variable afectada es más probable cuando están presentes

Inhibidor → la variable afectada es menos probable cuando están presentes

Receptor → si no entra en acción, no ocurre la variable afectada

Prevención → si entra en acción, no ocurre la variable afectada

Auxiliares → usados por conveniencia para simplificar el modelo

Relación causal $\xrightarrow{\text{ventaja}}$ ↑ sencillo de entender y ↓ complejo en parámetros y relaciones

(1) Si se cumple la relación de independencia: nodos sin padre + 2^n de padres

Si no es red Poysoniana: $2^{10} - 1$

Si un nodo tiene 3 valores: $1^0 + 3 \cdot 2^0 \rightarrow 8$ padres

pq necesitas 10 valores pq cuando en un nodo tienes 3 posibilidades
pues con saber 2 ya sacas la otra

Para tener un modelo más legible y menos complejo podemos agrupar los nodos

→ reduce complejidad pero pierde información

$$9 + 9 + 2 \xrightarrow{3 \text{ vías}} 3 \text{ vías} \text{ pernos}$$

4 nodos
si perno
4 nodos con
perno

• Especificación directa: de los pernos (sin ayuda de expertos, costosa)

→ En ausencia de información se sale superior equiprobabilidad

→ Se pueden utilizar relaciones tipo AND/OR.

• Aprendizaje: si existen BD

→ de pernos: si se dispone de la estructura

→ estructural: se aprende tanto la estructura como los pernos

• Combinaciones: de los 2 anteriores, iterativamente

MODELOS CANÓNICOS

A) No puede ser pq son factores que provocan HTA pero es la suma de ellos no que si tienen el perno 100% provoca el hijo.

Sí no hay ruido se pone 0 pero si hay alguna causa más se llama NOisy-OR y se pone así: $0 = 0,01$

$$P(g/g, 10) = P(f/g) + P(\bar{f}/g) \cdot P(g/\bar{f}, 10)$$

$$P(\bar{f} \times l | U_1, \dots, U_n) = \prod_{i \in I} q_i; q_i = 1 - c_i$$

lo primero + lo contrario. El que estaba puesto en el anterior en 1 y lo otro igual

$$P(\bar{f} | g, 10) = 1 - P(f | g, 10) = 1 - (0,2) = 0,8$$

$$P(f | g, 10) = 1 - P(\bar{f} | g, 10) = 1 - (0,2 \cdot 0,4) = 0,92$$

NOisy-OR: hay un 3^{er} elemento residual que es el que provoca que no sea 0 sino 0,01

↳ Si no se indica siempre se asume presente para hacer los cálculos.

$$P(f | g, 0) = 1 - P(\bar{f} | g, 0, r) = 1 - (0,4 \cdot 0,2 \cdot 0,99) = 0,9208$$

igual que la media ponderada en 100% sin ruido y el 3^{er} con ruido

$$P(f | g, 0, r) = 1 - P(\bar{f} | g, 0, r) = 1 - (0,4 \cdot 0,99) = 0,604$$

$$P(f, g, 10) = 1 - (0,2 \cdot 0,99) = 0,802$$

ruido

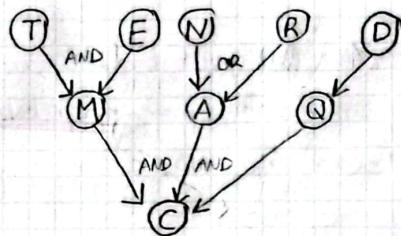
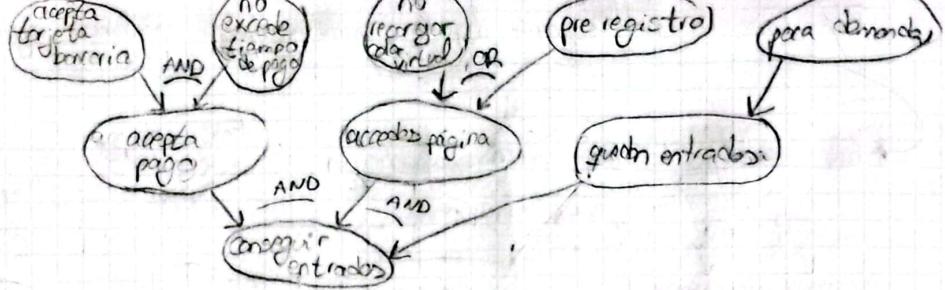
AND

Si hay que calcular perno AND calcularemos como OR con lógos de Morgan.

$$(A \text{ and } B) \equiv \bar{A}(\bar{A} \text{ and } B) = \bar{A} \text{ or } \bar{B}$$

$$\{\bar{A} \text{ or } B\} \equiv \bar{A} \text{ and } \bar{B}$$

Ejemplo:



$$1) T : Y \in \{E, N, R, D, A, Q\}$$

$$E : Y \in \{T, N, R, A, D, Q\}$$

$$N : Y \in \{T, E, R, D, Q\}$$

$$R : Y \in \{T, E, M, N, D, Q\}$$

$$D : Y \in \{T, E, M, N, R, A\}$$

$$M : Y \in \{N, R, A, D, Q\} \text{ dado } \{T, E\}$$

$$A : Y \in \{T, E, M, D, Q\} \text{ dado } \{N, R\}$$

$$Q : Y \in \{T, E, M, N, R, A\} \text{ dado } D$$

$$C : Y \in \{T, E, N, R, D\} \text{ dado } \{M, A, Q\}$$

$$3) 2^9 - 1$$

$$4) P(T, E, N, R, D, M, A, Q, C) = P(T) \cdot P(E) \cdot P(M/E, T) \cdot P(N) \cdot P(R) \cdot P(A/N, R) \cdot P(D) \cdot P(Q/D) \cdot P(C/N, A, Q)$$

5) Supongamos que queremos calcular la probabilidad de conseguir entradas dado que accedes a la página y no tienes entradas.

$$P(C/a, q) = \frac{P(c, a, q)}{P(a, q)} = \frac{\sum_{T, E, M, R, D} P(T, E, N, R, D, M, +a, +q, c)}{\sum_{T, E, M, R, D, C} P(T, E, M, R, D, M, +a, +q, c)}$$

Desarrollamos el concepto de probabilidad condicionada y en la división que obtenemos hay cuatro valores fijos tanto en el numerador como en el denominador por lo que cuando se desarrolla habrá que dejarlos fijos y ir cambiando los otros.

$$2) P(T) : P(t) = 0,6$$

$$P(E) : P(e) = 0,4$$

$$P(N) : P(n) = 0,7$$

$$P(R) : P(r) = 0,25$$

$$P(D) : P(d) = 0,3$$

$$P(A/N, R) \begin{cases} P(a/n, r) = 0,8 \\ P(a/\bar{n}, r) = 0,6 \\ P(a/n, \bar{r}) = 0,65 \\ P(a/\bar{n}, \bar{r}) = 0,1 \end{cases}$$

$$P(M/T, E) \begin{cases} P(m/t, e) = 0,99 \\ P(m/t, \bar{e}) = 0,1 \\ P(m/\bar{t}, e) = 0,1 \\ P(m/\bar{t}, \bar{e}) = 0,01 \end{cases}$$

$$P(Q/D) \begin{cases} P(q/d) = 0,9 \\ P(q/\bar{d}) = 0,2 \end{cases}$$

$$P(C/M, A, Q)$$

$$P(c/m, a, q) = 0,95$$

$$P(c/m, a, \bar{q}) = 0,01$$

$$P(c/\bar{m}, a, q) = 0,01$$

$$P(c/\bar{m}, a, \bar{q}) = 0,01$$

$$P(c/\bar{m}, \bar{a}, q) = 0,1$$

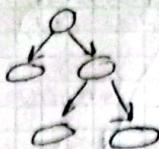
$$P(c/\bar{m}, \bar{a}, \bar{q}) = 0,01$$

$$P(c/\bar{m}, \bar{a}, \bar{q}) = 0,1$$

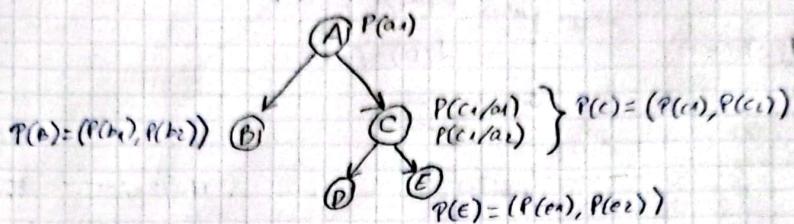
2) NO APROVADO

ALGORITMO DE PROPAGACIÓN EN ÁRBOLES

Solo se puede aplicar si es con:

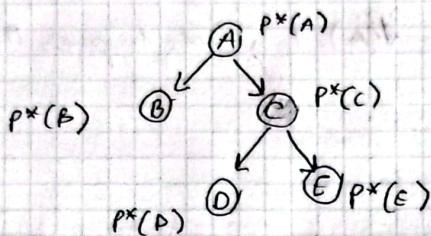


Estado S0 de la red
Estado inicial



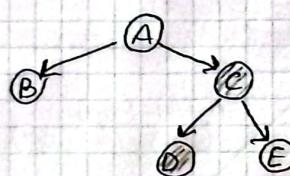
Tenemos una evidencia de que $e = \{C=c_1\}$

Estado S1 de la red



Una vez calculados todos P^* pasamos al estado S1 de la red

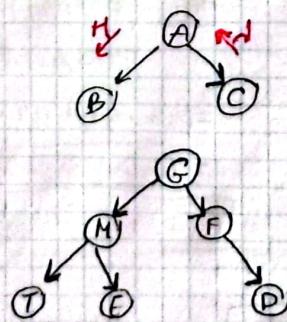
Estado S2 de la red



Recalculamos P^* y pasmos al estado S2
Nodos C y D instanciados

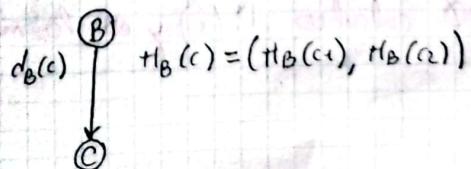
d-valor = $d(x)$ cambia cuando un hijo de X se instancia, gracias a un d-mensaje
h-valor = $h(x)$ cambia cuando un padre de X se instancia, gracias a un h-mensaje

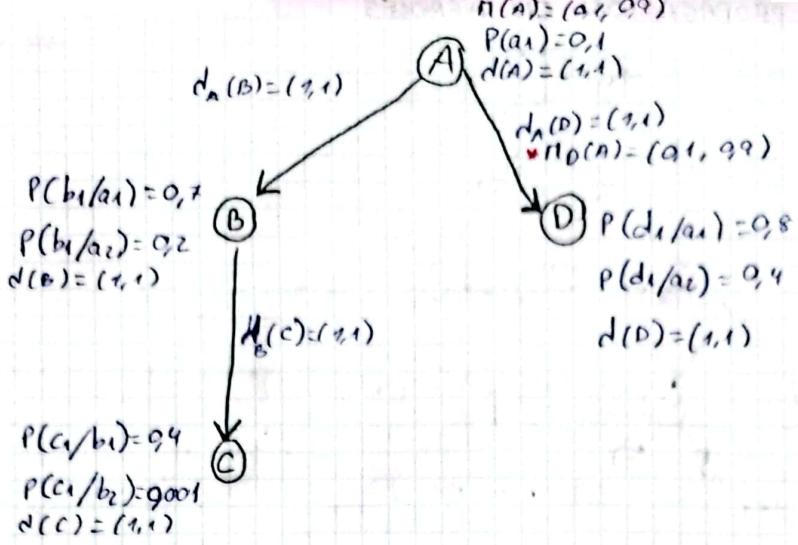
Ej:



h: el producto se aplica en los hijos de A que no son el que le manda el msg

h-padre (hijo)



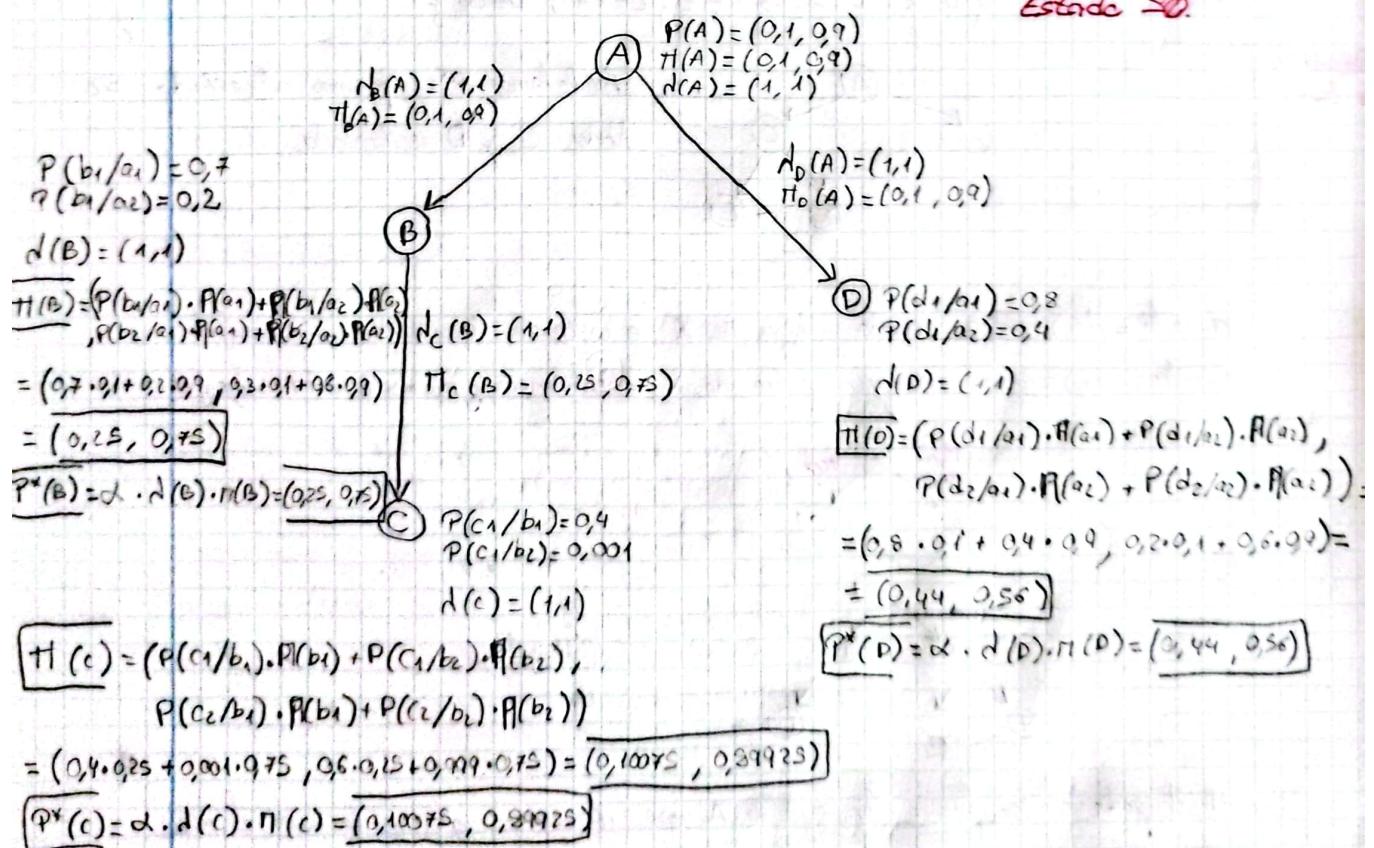


Como $P(A) = \alpha \cdot H_A(A) \cdot d(A)$ y $d(A) = 1$ y $\alpha = 1$ pues $H(A) = P(A)$ por lo que *

$H(A) \cdot d_B(A) = H_A$ para el nodo D

EJERCICIO PASO A PASO

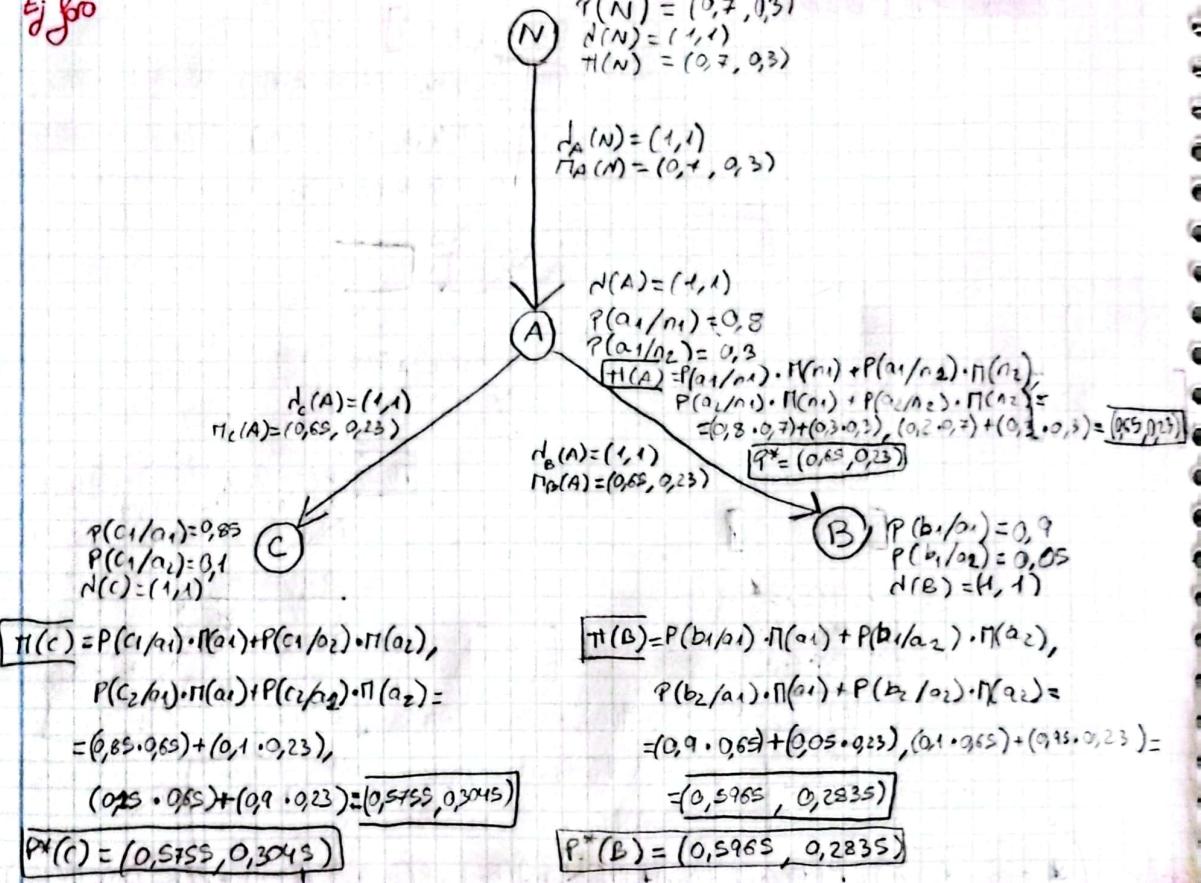
Estado S0.



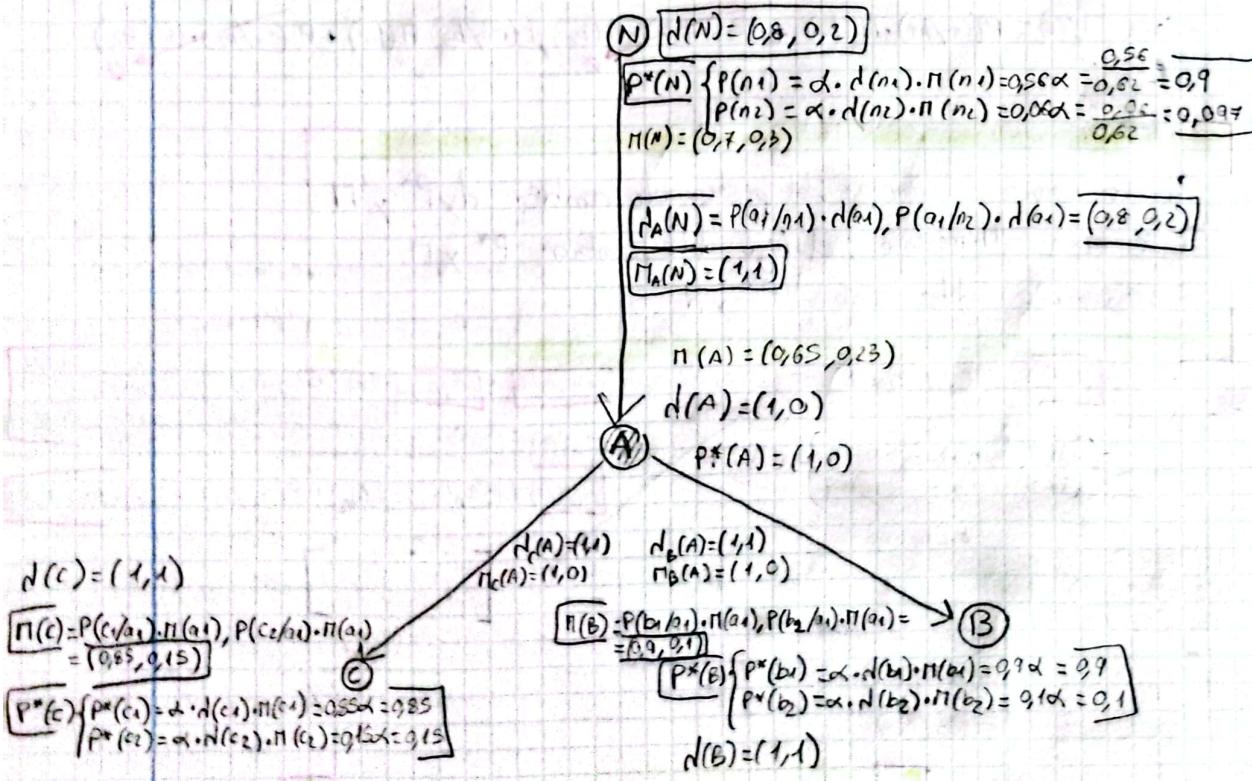
En el S0 calculo $H(x)$ y es lo mismo que $P^*(x)$, solo por la fórmula y ya

SO

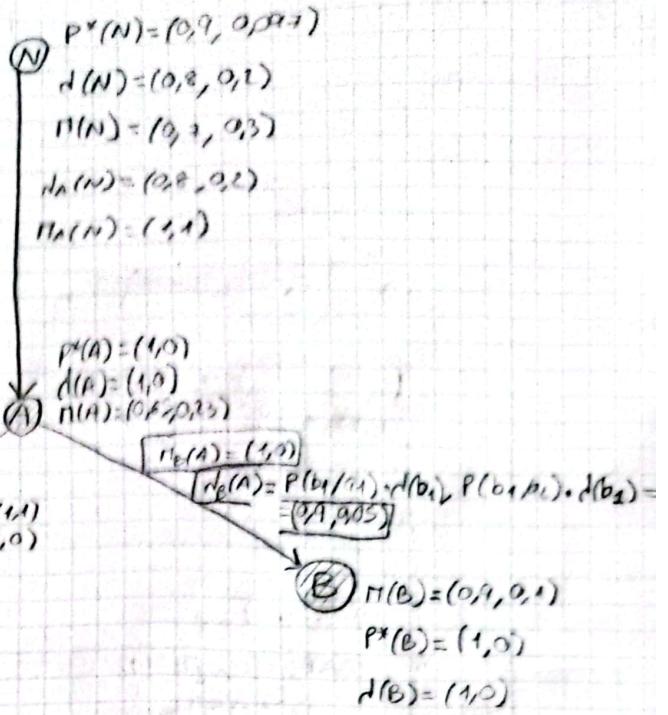
Ej 60



Estado s1 $\rightarrow A=a_1$



Estudar S2 \rightarrow B = b1



$$P(\text{S2/g, +0, 7r}) = 1 - P(\text{S2/g, 0, 7r}) = 1 - (0, 2 \cdot 0, 4 \cdot 0, 90) = 0, 9208$$

S2

Node A:

- $d_B(A) = (1, 1)$
- $n_B(A) = (0, 3, 0, 5, 0, 2)$
- $M(B) = (P(b_1/a_1) \cdot n(a_1) + P(b_1/a_2) \cdot n(a_2) + P(b_1/a_3) \cdot n(a_3)) + (P(b_2/a_1) \cdot n(a_1) + P(b_2/a_2) \cdot n(a_2) + P(b_2/a_3) \cdot n(a_3)) = (0, 1 \cdot 0, 2 + 0, 3 \cdot 0, 2 + 0, 2 \cdot 0, 2) + (0, 9 \cdot 0, 3 + 0, 2 \cdot 0, 2 + 0, 2 \cdot 0, 2) = (0, 22, 0, 78)$
- $d(B) = (1, 1)$

Node D:

- $P(d_1/a_1) = 0, 9 ; P(d_1/a_2) = 0, 2 ; P(d_1/a_3) = 0, 2$
- $n(D) = (1, 1)$
- $n(D) = (P(d_1/a_1) \cdot n(a_1) + P(d_1/a_2) \cdot n(a_2) + P(d_1/a_3) \cdot n(a_3)), (P(d_2/a_1) \cdot n(a_1) + P(d_2/a_2) \cdot n(a_2) + P(d_2/a_3) \cdot n(a_3)) = (0, 9 \cdot 0, 3 + 0, 7 \cdot 0, 5 + 0, 3 \cdot 0, 2), (0, 1 \cdot 0, 3 + 0, 3 \cdot 0, 5 + 0, 7 \cdot 0, 8) = (0, 68, 0, 74)$
- $P^*(D) = 0 \cdot d(D) \cdot n(D) = (0, 68, 0, 74)$

Node C:

- $P(c_1/b_1) = 0, 9$
- $P(c_1/b_2) = 0, 1$
- $n(C) = (1, 1)$
- $n(C) = (P(c_1/b_1) \cdot n(b_1) + P(c_1/b_2) \cdot n(b_2)) = (P(c_2/b_1) \cdot n(b_1) + P(c_2/b_2) \cdot n(b_2)) = (0, 9 \cdot 0, 12 + 0, 1 \cdot 0, 8, 78), (0, 1 \cdot 0, 12 + 0, 9 \cdot 0, 78) = (0, 276, 0, 724)$
- $P^*(C) = 0 \cdot d(C) \cdot n(C) = (0, 276, 0, 724)$

51.

$$A \quad I(A) = (0,1,0,1,0,1)$$

$$P^*(A) = d_1 \cdot d_{01} \cdot n_{01} = 0,1 \cdot 0,3 = 0,03 \alpha \Rightarrow 0,14$$

$$d_1 \cdot d_{01} \cdot n_{01} = 0,3 \cdot 0,2 = 0,15 \alpha \Rightarrow 0,65$$

$$d_1 \cdot d_{01} \cdot n_{01} = 0,1 \cdot 0,2 = 0,02 \alpha \Rightarrow 0,12$$

$$n_A(A) = (0,1,0,1,0,1)$$

$$\begin{aligned} P_A(A) &= P(b_1/a_1) \cdot d(b_1) + \\ &+ P(b_1/a_2) \cdot n(b_1) + P(b_1/a_3) \cdot d(b_1) + \\ &+ P(b_1/a_4) \cdot n(b_1) + P(b_1/a_5) \cdot d(b_1) + \\ &+ P(b_1/a_6) \cdot n(b_1) = (0,1,0,3,0,2) \end{aligned}$$

$$P^*(B) = (1,0)$$

$$I(B) = (1,0)$$

$$n_C(B) = (1,1)$$

$$d(C) = (1,1)$$

$$\begin{aligned} C \quad M(C) &= P(c_1/b_1) \cdot M(b_1) + P(c_1/b_2) \cdot n(b_2) \\ &+ P(c_2/b_1) \cdot n(b_1) + P(c_2/b_2) \cdot n(b_2) \\ &= (0,9,0,1) \end{aligned}$$

$$P^*(C) = \alpha \cdot d(C) \cdot M(C) \quad \left\{ \begin{array}{l} \alpha \cdot d(c_1) \cdot M(c_1) = \alpha \cdot 0,9 \\ \alpha \cdot d(c_2) \cdot n(c_2) = \alpha \cdot 0,1 \end{array} \right\} \alpha \cdot (0,9 + 0,1) = 1 ; \underline{\alpha = 1}$$

$$P^*(C) = (0,9,0,1)$$

$$\alpha(0,03 + 0,15 + 0,04) = 1$$

$$\alpha = \frac{1}{0,22} = 4,54$$

$$\begin{aligned} D \quad M_D &= 0,3 \cdot 0,1, 0,5 \cdot 0,3, 0,2 \cdot 0,2 = \\ &= (0,03, 0,15, 0,04) \end{aligned}$$

$$d_D(A) = (0,3,0,5,0,2)$$

$$\begin{aligned} D \quad P(D) &= P(d_1/a_1) \cdot n(a_1) + P(d_1/a_2) \cdot n(a_2) \\ &+ P(d_1/a_3) \cdot n(a_3) + P(d_2/a_1) \cdot n(a_1) + \\ &P(d_2/a_2) \cdot n(a_2) + P(d_2/a_3) \cdot n(a_3) = \\ &= (0,9 \cdot 0,03) + (0,7 \cdot 0,15) + (0,3 \cdot 0,02) \\ &+ (0,1 \cdot 0,03) + (0,3 \cdot 0,15) + (0,2 \cdot 0,02) = (0,09, 0,21, 0,06) \\ &P(d_1/a_1) = 0,9 \quad P(d_1/a_2) = 0,7 \quad P(d_1/a_3) = 0,3 \end{aligned}$$

$$\begin{aligned} D \quad P^*(D) &= \left\{ \begin{array}{l} d_1 \cdot d(d_1) \cdot M(d_1) = 0,144 \alpha = 0,65 \\ d_2 \cdot d(d_2) \cdot M(d_2) = 0,076 \alpha = 0,33 \end{array} \right. \\ &\alpha = 1,54 \end{aligned}$$