

# Tema 1

"Sistemas basados en el conocimiento"

## 1. Introducción

Usa una base de conocimiento para razonar y resolver problemas complejos.

Funcionalidades ⇒

- \* Aceptar las consultas
- \* Aceptar los datos y solicitar otros
- \* Procesar la información
- \* Emitir y justificar la respuesta hallada
- \* Autoaprendizaje

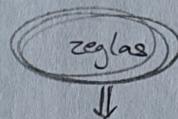
## 2. Arquitectura y motores de inferencia

! SBC basado en reglas !

### • Base de conocimientos

Contiene el conocimiento experto → relaciones entre los objetos

Naturaleza estática → no cambia a menos que se introduzcan nuevas



### • Memoria de trabajo

Contiene las conclusiones o hipótesis que se generan en el proceso de razonamiento a partir de los datos del caso.

Naturaleza dinámica → cambia de una sesión a otra

### • Motores de inferencia

## Datos del caso

Datos memoria de trabajo  
+



obtiene nuevas conclusiones  
o hipótesis

## Conocimiento de la BC

(se añaden a la memoria de trabajo)

Puede solicitar nuevos datos al usuario

## MODUS PONENS

$$P \rightarrow q$$

$$P$$

$$\hline q$$

## MODUS TOLLENS

$$P \rightarrow q$$

$$\neg q$$

$$\hline \neg P$$

Ej!

Mem. Trab

Datos →

Conj. Reglas

R <sub>1</sub>
R <sub>2</sub>
:
:
R <sub>10</sub>

R. Aplicables

R <sub>1</sub>
R <sub>5</sub>
R <sub>10</sub>



⊗

R<sub>5</sub> →

aplico

R<sub>5</sub>

aplico

nueva info.  
hipótesis o  
conclusiones

① Estrategias

② Resolver conflictos

→ **Estrategias** de los motores de inferencia :

① Encadenamiento de reglas hacia adelante (partimos de hechos conocidos)

② Encadenamiento de reglas hacia atrás (partimos de un objetivo a demostrar)

¡Merda!

→ Criterios de resolución de conflictos: estáticos, dinámicos o dinámicos manipulables. (ej.) → orden lexicográfico

→ Criterios de parada (ej.) → no es posible aplicar más reglas

## Tema 2

### "Redes bayesianas"

#### 1. Conceptos básicos de probabilidad

- Probabilidad condicionada

$$P(x|y) = \frac{P(x,y)}{P(y)}$$

Si  $x$  e  $y$  son independientes  $\Rightarrow P(x,y) = P(x) \cdot P(y)$

Si  $x$  e  $y$  son dependientes  $\Rightarrow \begin{cases} P(x,y) = P(x) \cdot P(y|x) \\ P(x,y) = P(y) \cdot P(x|y) \end{cases}$

- Teorema de Bayes

$$P(y|x) = \frac{P(y) \cdot P(x|y)}{P(x)}$$

- Ley de probabilidad total

$$P(x) = P(y_1) \cdot P(x|y_1) + P(y_2) \cdot P(x|y_2) + \dots$$

- Probabilidad marginal a partir de la distribución conjunta

$$P(x_j = x_j) = \sum P(x_1, x_2, \dots, x_n)$$

• Independencia condicional

$$P(x, y|z) = P(x|z) \cdot P(y|z)$$

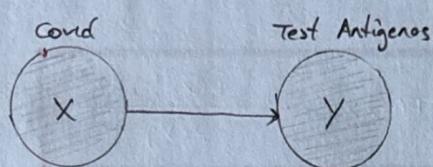
2. Presentación intuitiva

Nodo → variable o entidad del mundo real ( $x$ )

Valor →  $x$  ( $+x = \text{si}$ ,  $\neg x = \text{no}$ )

Arcos → une dos nodos, representa una relación de influencia causal

15!



$$P(+x) = 0,099 \quad (\text{tengo covid})$$

$$P(+y|+x) = 0,9$$

$$P(+y|\neg x) = 0,05$$

Sacamos :

④ Probabilidad no tengo covid  $\Rightarrow P(\neg x) = 1 - 0,099 = \boxed{0,901}$

⑤ Probabilidad tengo covid y soy positivo  $\Rightarrow P(+y|+x) = \boxed{0,9}$

⑥ Probabilidad no tengo covid y soy positivo  $\Rightarrow P(+y|\neg x) = \boxed{0,05}$

## CONCEPTO DE INFERENCIA

④ Probabilidad a priori de que una persona sea positiva en un test :

$$P(+y) = P(+x) \cdot P(+y|+x) + P(\neg x) \cdot P(+y|\neg x) = \boxed{0,134}$$

$$P(\neg y) = 1 - P(+y) = \boxed{0,865}$$

Inferencia a partir de datos  $\Rightarrow$  probabilidad a posteriori dada una evidencia observada

④ Si he dado positivo en el test, ¿cuál es la probabilidad de que tenga covid?

$$\underline{\underline{P^*(x) = P(x/e)}} \rightarrow \text{el hecho que se}$$

$$P^*(+x) = P(+x / +y) = \frac{P(+x) \cdot P(+y / +x)}{P(+y)} = [0,664]$$

**Ojo!**  $\Rightarrow$  expresión general del teorema de Bayes

$$P^{**}(x) = P(x/y) = \frac{P(x) \cdot P(y/x)}{P(y)} \implies P^*(x) = \alpha \cdot P(x) \cdot \frac{x(x)}{P(y)}$$

Sacamos  $\alpha$  normalizando ( $\square + \square = 1$ )

obtenemos  $P^*(x)$

### 3. Definición formal de R. Bayesiana (Genero Tipo)

Formada por:

variable aleatoria que forma un conjunto exhaustivo y excluyente de valores

variables proposicionales + conjunto de relaciones binarias + distinción de probabilidad conjunta

Cumple que:

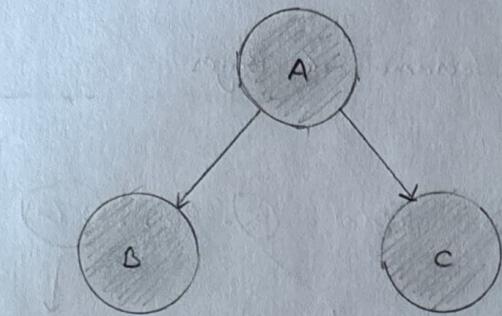
$(V, E) \rightarrow$  grafo acíclico, conexo y dirigido

$(\alpha, P) \rightarrow$  hipótesis de independencia condicional

- Hipótesis independencia condicional

$\forall x \in V \text{ y } \forall y \in V - \{x\} \cup \text{descendientes}(x) \cup \text{padres}(x)$  si  
 $x$  es independiente de  $y$  dado  $\text{padres}(x)$

Ejemplo! Comprobar si una red es bayesiana



- $x = A \Rightarrow A : y \in \emptyset$
- $x = B \Rightarrow B : y \in \{C\}$  dado  $A$
- $x = C \Rightarrow C : y \in \{B\}$  dado  $A$

Comprobar si  $B$  es independiente de  $C$  dado  $A$

$$P(b_1/a_1, c_1) = \frac{P(a_1, b_1, c_1)}{P(a_1, c_1)} = \frac{1}{4}$$

NO

$$P(b_1/c_1) = \frac{P(b_1, c_1)}{P(c_1)} = \frac{3}{7}$$

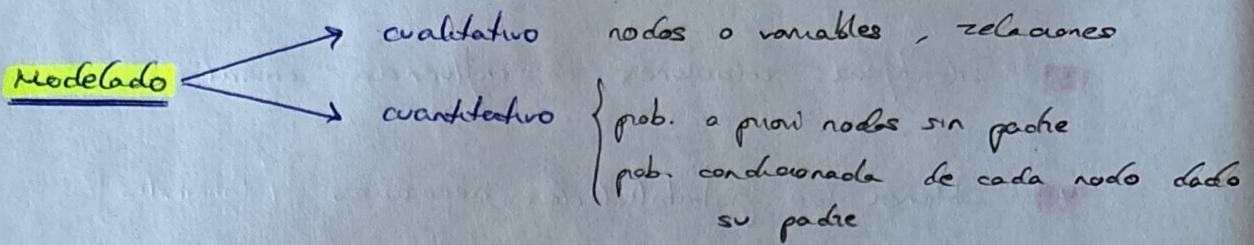
#### 4. Teorema Fundamental. Factorización de la probabilidad

La distribución de probabilidad de una red bayesiana puede expresarse:

$$P(x_1, \dots, x_n) = \prod P(x_i / \text{padre}(x))$$

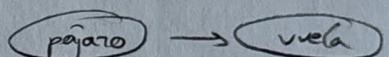
sin se requieren muchas prob. conjuntas !!

## 5. Modelado con redes bayesianas



### IMPORTANTE

- Quiero representar las enfermedades  $\Rightarrow$  mejor nodos separados con valores si/no porque puedo tener varias enfermedades a la vez
- Si los valores de una variable son únicas (solo puede tomar uno)  
 $\Rightarrow$  crea una variable con todas las causas **!j!** especie
- Relaciones de influencia causal  $\Rightarrow$  "si gripe entonces tos"



- Las probabilidades deben ser acordes con el sentido común
- Diferencia entre el OR y AND  $\Rightarrow$  true && true = true  
true && false = false  
true || false = true

(...)

- Pasos para modelar una red bayesiana

- ① Identificar información relevante del problema

2º Representar variables y conjunto de valores *! Exclusivo y exhaustivo !*

3º Identificar relaciones de influencia causal

4º Obtener las probabilidades necesarias *! Coherentes !*

15/1!

[1,2] Estornudo = {si, no}

Gato = {si, no}

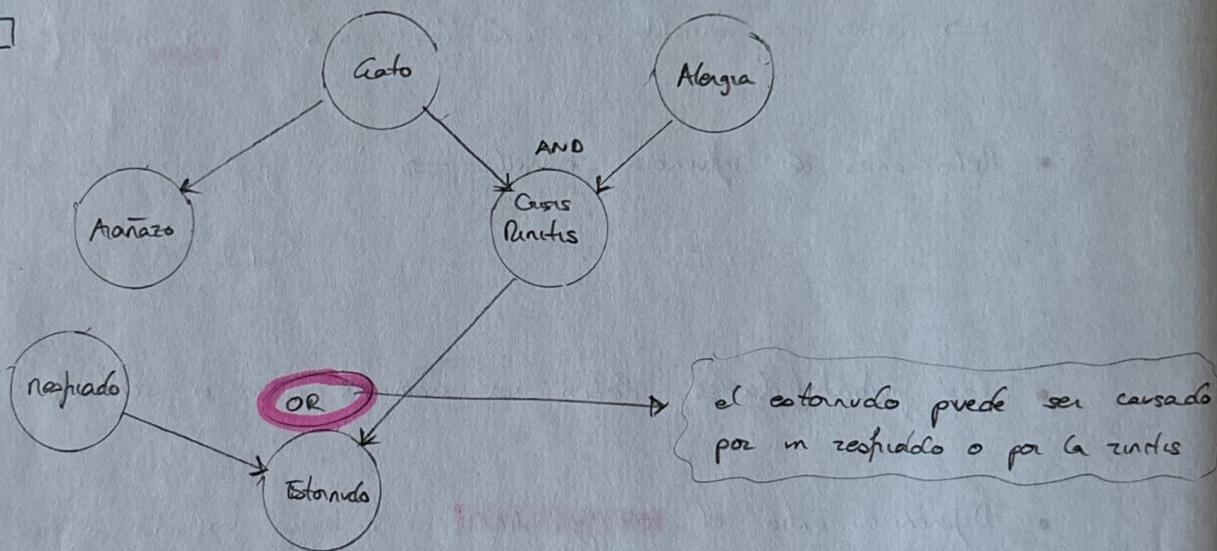
Respirado = {si, no}

Rinitis = {si, no}

Arañazo = {si, no}

Alergia = {si, no}

[3]



$$[4] P(G) = 0,2 \quad P(A) = 0,45 \quad P(Res) = 0,5$$

$$P(\text{arañazo} / \neg \text{gato}) = 0,15 \quad P(\text{arañazo} / \text{gato}) = 0,95$$

$$P(\text{rinitis} / \text{gato}, \text{alergia}) = 0,99$$

$$P(\text{estornudo} / \text{respirado}, \neg \text{rinitis}) = 0,99$$

$$P(\text{rinitis} / \neg \text{gato}, \text{alergia}) = 0,1$$

$$P(\text{estornudo} / \neg \text{respirado}, \neg \text{rinitis}) = 0,9$$

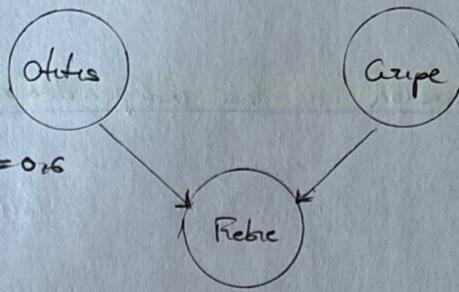
$$P(\text{rinitis} / \text{gato}, \neg \text{alergia}) = 0,15$$

$$P(\text{estornudo} / \text{respirado}, \neg \text{rinitis}) = 0,85$$

$$P(\text{rinitis} / \neg \text{gato}, \neg \text{alergia}) = 0,005$$

$$P(\text{estornudo} / \neg \text{respirado}, \neg \text{rinitis}) = 0,01$$

150!



- Puerta OR      Objetivo  $\longrightarrow$   $P(F/O, G)$

$$P(+f/\neg g, \neg o) = 0$$

$$P(+f/+g, \neg o) = P(+f/+g) + P(\neg f/+g) \cdot P(+f/\neg g, \neg o) \xrightarrow{o} = c_g = 0,8$$

$$P(+f/\neg g, +o) = P(+f/+o) + P(\neg f/+o) \cdot P(+f/\neg g, +o) \xrightarrow{o} = c_o = 0,6$$

$$\begin{aligned} P(+f/+g, +o) &= P(+f/+g) + P(\neg f/+g) \cdot P(+f/\neg g, +o) = \\ &= 0,8 + (0,2 \cdot 0,6) = \boxed{0,92} \end{aligned}$$

- Puerta Noisy - OR

• P

$$P(+f/\neg g, \neg o) = c_z = 0,01 \quad (\text{ruido})$$

$$(H1, H4) \Rightarrow P(+f/+g, +o, \neg z) = P(+f/+g, \neg o, \neg z) + P(\neg f/+g, \neg o, \neg z).$$

$$P(+f/\neg g, +o, \neg z) = 0,8 + (0,2 \cdot 0,01) = \boxed{0,92}$$

$$(H2) \Rightarrow P(+f/\neg g, \neg o, \neg z) = 0$$

$$\begin{aligned} P(+f/+g, +o) &= P(+f/+g, +o, \neg z) + P(\neg f/+g, +o, \neg z) \cdot P(+f/\neg g, \neg o) = \\ &= 0,92 + (0,08 \cdot 0,01) = \boxed{0,9208} \end{aligned}$$

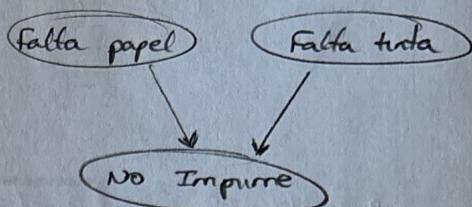
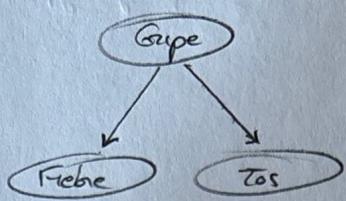
$$P(+f/+g, \neg o) = P(+f/+g, \neg o, \neg z) + P(\neg f/+g, \neg o, \neg z) \cdot P(+f/\neg g, \neg o) =$$

$$P(+f/\neg g, \neg o) = 0,8 + (0,2 \cdot 0,01) = \boxed{0,802}$$

$$P(+f/\neg g, +o) = P(+f/\neg g, +o, \neg z) + P(\neg f/\neg g, +o, \neg z) \cdot P(+f/\neg g, \neg o) =$$

$$= 0,6 + (0,4 \cdot 0,01) = \boxed{0,604}$$

- VARIABLES: verificación de las independencias



Fiebre y Tos son dependientes  
a priori pero independientes dado gripe

- Parámetros (probabilidades)

→ Especificación directa ( $\text{and}, \text{or}$ ) es normalmente si no tengo info.  
premisa, asumo equiprobabilidad

Modelo Noisy-OR

H1 \* Cada causa, por sí misma, puede producir el efecto

H2 \* Ruido → hay causas desconocidas, no individuos en la red, que pueden producir el efecto

H3 \* No hay interacción entre las causas

H4 \* El efecto se produce solo por alguna causa modelada o por ruido.

Modelo Noisy-And

$$\neg(A \text{ and } B) \equiv \neg A \text{ or } \neg B$$

$$\neg(A \text{ or } B) \equiv \neg A \text{ and } \neg B$$

Ajustar los pesos  
y calcular el efecto

Dada las prob. cond. por un solo pañuelo y el factor ruido, se pueden calcular las prob. cond. por todos los pañuelos

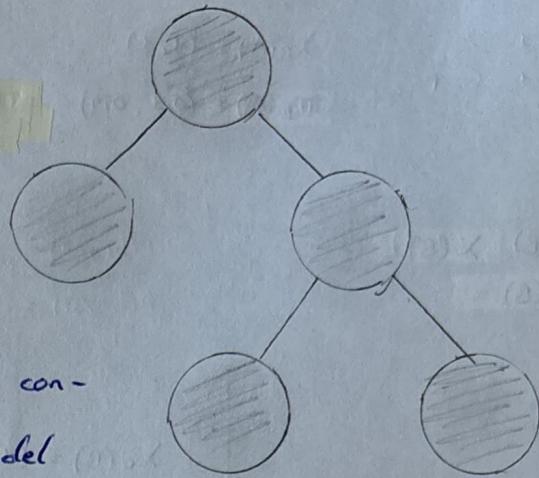
$$\Rightarrow \boxed{\text{Truco}} \quad P(\neg x / u_1, \dots, u_n) =$$

$$\prod_{i \in T_u} g_i$$

↑  
(conjunto de causas de x presentes)

## 6. Algoritmo de propagación de probabilidades en árboles

Árbol (cada nodo a lo sumo un padre)



Algoritmo → sigue para calcular

las nuevas probas de los nodos conforme se va teniendo evidencia del caso concreto

### • Idea general

$$P(x) = \alpha \cdot \lambda(x) \cdot \pi(x)$$

$\lambda$ -valor (cambia cuando un hijo de  $x$  se instancia)

$\alpha$  (constante de normalización)

$\pi$ -valor (cambia cuando el padre de  $x$  se instancia)

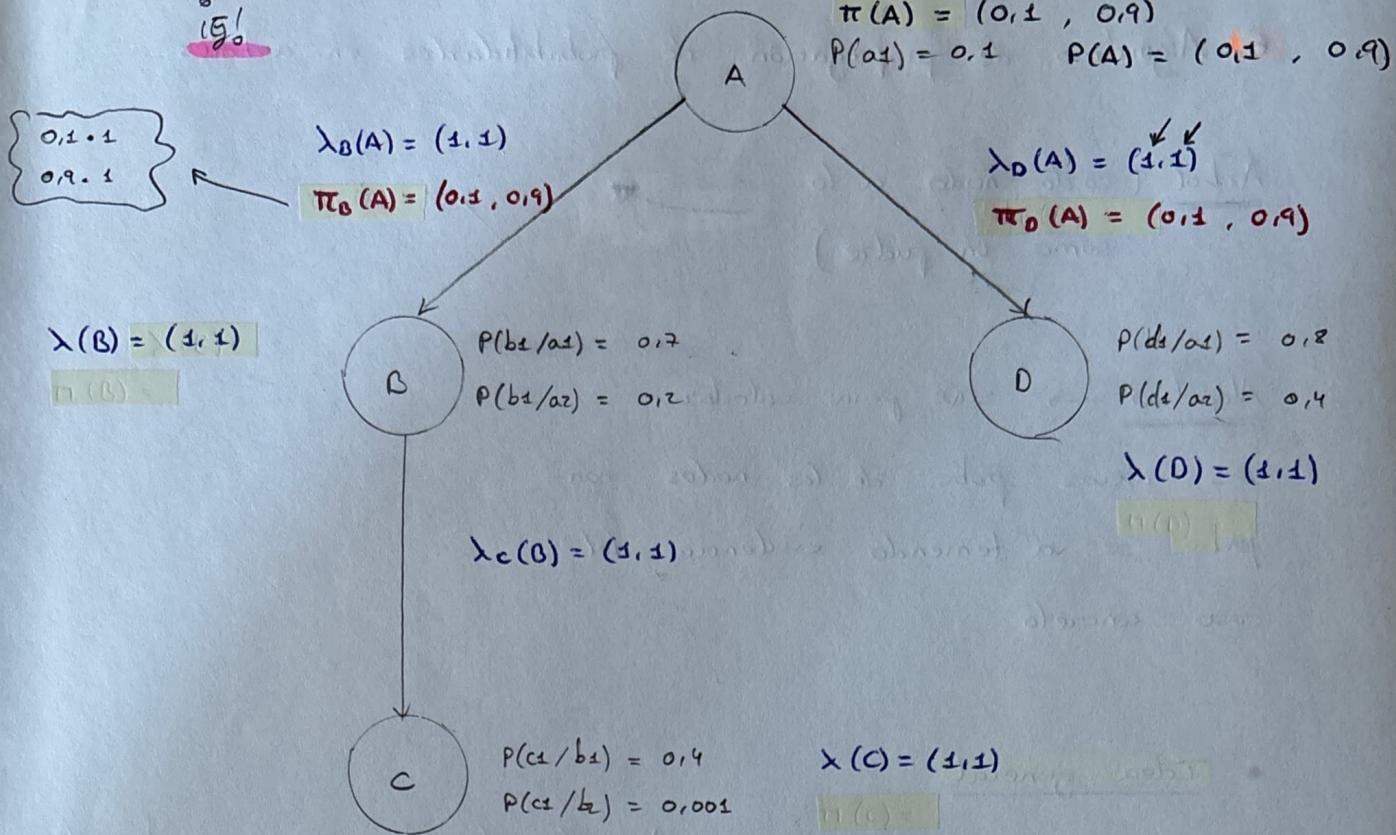
{ Un nodo se instancia }  $\Rightarrow$  manda  $\lambda$ -mensaje a su padre y  $\pi$ -mensaje a sus hijos

## INGISO

$$P(+x) = \alpha \cdot 0,2 \Rightarrow \alpha = \frac{0,2}{0,2 + 0,4}$$

$$P(\neg x) = \alpha \cdot 0,4 \Rightarrow \alpha = \frac{0,4}{0,2 + 0,4}$$

15!



- ① Probabilidades condicionadas de cada nodo dados sus padres
- ② Probabilidades a priori de todos los nodos

+ Inicialización A B C

+ B ha recibido un π-mensaje de A ( $\pi_B(A) = (0, 1, 0, 9)$ )

→ Aplicamos el C

$$\pi(B) = (0, 7 \cdot 0, 1 + 0, 2 \cdot 0, 9, 0, 3 \cdot 0, 1 + 0, 8 \cdot 0, 9) = (0, 25, 0, 75)$$

$$P^*(B) = \begin{cases} 0 \cdot 1 \cdot 0, 25 \\ 0 \cdot 1 \cdot 0, 75 \end{cases} \Rightarrow P^*(B) = (0, 25, 0, 75)$$

$$\pi_c(B) = (0, 25, 0, 75)$$

Ahora, si se instancia una variable pasariamos a un nuevo estado  $S_1, S_2, \dots$  actualizando el árbol.

### Fórmulas para el cálculo de $\lambda$ y $\pi$ -mensajes, $\lambda$ y $\pi$ -valores y probabilidades $P^*$ .

1. Si  $B$  es un hijo de  $A$ ,  $B$  tiene  $k$  valores posibles y  $A$   $m$  valores posibles, entonces para  $j=1,2,\dots,m$ , el  $\lambda$ -mensaje de  $B$  a  $A$  viene dado por;

$$\lambda_B(a_j) = \sum_{i=1}^k P(b_i / a_j) \lambda_i(b_i).$$

2. Si  $B$  es hijo de  $A$  y  $A$  tiene  $m$  valores posibles, entonces para  $j=1,2,\dots,m$ , el  $\pi$ -mensaje de  $A$  a  $B$  viene dado por;

$$\pi_B(a_j) = \begin{cases} \pi(a_j) \prod_{\substack{C \in s(A) \\ C \neq B}} \lambda_C(a_j) & \text{si } A \text{ no ha tomado ningún valor} \\ 1 & \text{si } A = a_j \\ 0 & \text{si } A \neq a_j \end{cases}$$

donde  $s(A)$  denota al conjunto de hijos de  $A$ .

3. Si  $B$  tiene  $k$  valores posibles y  $s(B)$  es el conjunto de los hijos de  $B$ , entonces para  $i=1,2,\dots,k$ , el  $\lambda$ -valor de  $B$  viene dado por;

$$\lambda(b_i) = \begin{cases} \prod_{C \in s(B)} \lambda_C(b_i) & \text{si } B \text{ no ha tomado ningún valor} \\ 1 & \text{si } B = b_i \\ 0 & \text{si } B \neq b_i. \end{cases}$$

4. Si  $A$  es padre de  $B$ ,  $B$  tiene  $k$  valores posibles y  $A$  tiene  $m$  valores posibles, entonces para  $i=1,2,\dots,k$ , el  $\pi$ -valor de  $B$  viene dado por;

$$\pi(b_i) = \sum_{j=1}^m P(b_i / a_j) \pi_B(a_j).$$

5. Si  $B$  es una variable con  $k$  posibles valores, entonces para  $i = 1,2,\dots,k$  la probabilidad a posteriori basada en las variables instanciadas se calcula como:

$$P^*(b_i) = \alpha \lambda(b_i) \pi(b_i).$$

### ALGORITMO:

#### 1. Inicialización.

- A. Inicializar todos los  $\lambda$ -mensajes y  $\lambda$ -valores a 1.
- B. Si la raíz  $A$  tiene  $m$  posibles valores, entonces para  $j=1,\dots,m$ , sea  $\pi(a_j) = P(a_j)$ .

- C. Para todos los hijos  $B$  de la raíz  $A$ , hacer

Enviar un nuevo  $\pi$ -mensaje a  $B$  usando la fórmula 2.

(En ese momento comenzará un flujo de propagación debido al procedimiento de actualización C).

Cuando una variable se instancia o una variable recibe un  $\lambda$  o  $\pi$ -mensaje, se usa uno de los siguientes procedimientos de actualización;

#### Actualización.

- A. Si una variable  $B$  se instancia a un valor  $b_j$ , entonces

BEGIN

1. Inicializar  $P^*(b_j) = 1$  y  $P^*(b_i) = 0$ , para todo  $i \neq j$ .
2. Calcular  $\lambda(B)$  usando la fórmula 3.
3. Enviar un nuevo  $\lambda$ -mensaje al padre de  $B$  usando la fórmula 1.
4. Enviar nuevos  $\pi$ -mensajes a los hijos de  $B$  usando la fórmula 2.

END

- B. Si una variable  $B$  recibe un nuevo  $\lambda$ -mensaje de uno de sus hijos y la variable  $B$  no ha sido instanciada todavía, entonces,

BEGIN

1. Calcular el nuevo valor de  $\lambda(B)$  usando la fórmula 3.
2. Calcular el nuevo valor de  $P^*(B)$  usando la fórmula 5.
3. Enviar un nuevo  $\lambda$ -mensaje al padre de  $B$  usando la fórmula 1.
4. Enviar nuevos  $\pi$ -mensajes a los otros hijos de  $B$  usando la fórmula 2.

END.

- C. Si una variable  $B$  recibe un nuevo  $\pi$ -mensaje de uno de sus padres y la variable  $B$  no ha sido instanciada todavía, entonces,

BEGIN

1. Calcular el nuevo valor de  $\pi(B)$  usando la fórmula 4.
2. Calcular el nuevo valor de  $P^*(B)$  usando la fórmula 5.
3. Enviar nuevos  $\pi$ -mensajes a los hijos de  $B$  usando la fórmula 2.

END.

a) Un grafo acíclico conexo y dirigido  $G = (V, E)$  y una distribución de probabilidad conjunta  $P$  definida sobre  $V$  se dice que cumple la h.i.c si

$$\forall x \in V \text{ y } \forall y \in V - \{x\} \cup \text{pa}(x) \quad \{y\}$$

$x$  es independiente de  $y$  dado  $\text{pa}(x)$

Para

d) ^ cualquier conjunto de variables aleatorias, la probabilidad conjunta se puede calcular a partir de las probabilidades condicionadas:

$$P(x_1, \dots, x_n) = \prod_{x_i} P(x_i / \text{pa}(x_i))$$

!Dada una red bayesiana!



## Definición Formal Red Bayesiana

Una red bayesiana es

variable aleatoria que toma un conjunto exhaustivo y excluyente

- Un conjunto de variables proposicionales  $V$  de valores
- Un conjunto de relaciones binarias  $E$  definidas sobre las variables  $V$
- Una distribución de probabilidad conjunta  $P$  sobre las variables  $V$

tales que:

- $(V, E)$  forman un grafo acíclico, conexo y dirigido a
- $(A, P)$  cumplen la hipótesis de independencia condicional